



Manipulación de datos y automatización con R

Inferencia estadística: Intervalos de confianza y Pruebas de hipótesis

Mg. J. Eduardo Gamboa U.

2026-07-19

Estimación puntual

Sea $X_1, \dots, X_n$ una muestra de tamaño n de una población con parámetro θ . Se denomina estimador puntual de θ a cualquier estadístico $\hat{\Theta} = h(X_1, \dots, X_n)$ cuyo valor $\hat{\theta} = h(x_1, \dots, x_n)$ dará una estimación puntual de θ . En este caso, Θ es una variable aleatoria y $\hat{\theta}$ es un número (aunque en el caso particular de la moda podría no serlo).

Estimador puntual de la media:

$$\hat{\mu} = \bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

Estimador puntual de la variancia:

$$\hat{\sigma}^2 = s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

Estimador puntual de la proporción:

$$\hat{\pi} = p = \frac{\text{Número de éxitos}}{n}$$

Estimación intervalar

Sea $X_1, \dots, X_n$ una muestra aleatoria de tamaño n de una población con parámetro desconocido θ . Sean $x_1, \dots, x_n$ valores observados de dicha muestra.

Sean además $a = h_1(x_1, \dots, x_n)$ y $b = h_2(x_1, \dots, x_n)$ dos valores numéricos calculados a partir de los datos, con $a \leq b$. Entonces, el intervalo $[a, b]$ es un intervalo de confianza para θ con un nivel de confianza $1 - \alpha$ si se cumple que:

$$P(h_1(x_1, \dots, x_n) \leq \theta \cap h_2(x_1, \dots, x_n) \geq \theta) = P(h_1(x_1, \dots, x_n) \leq \theta \leq h_2(x_1, \dots, x_n)) = 1 - \alpha$$

En otras palabras, el intervalo $[a, b]$ tiene un nivel de confianza del $(1 - \alpha) \times 100\%$ de contener el parámetro θ , o que $\theta \in [a, b]$ con un nivel de confianza del $(1 - \alpha) \times 100\%$.

Interpretación: Con un nivel de confianza del $(1 - \alpha) \times 100\%$, se estima que el parámetro desconocido θ está contenido en el intervalo $[a, b]$.

Si se repitiera este experimento muchas veces, cada vez obteniendo una nueva muestra aleatoria del mismo tamaño y construyendo un nuevo intervalo mediante la misma regla, entonces aproximadamente el $(1 - \alpha)\%$ de esos intervalos incluirían el verdadero valor del parámetro θ .

Estimación de la media por intervalo de confianza

Caso teórico: varianza poblacional conocida

Si $X_1, \dots, X_n$ es una muestra aleatoria de una población Normal con media μ y σ^2 conocida, el intervalo con un nivel de confianza del $(1 - \alpha) \times 100\%$ para la media μ se obtiene mediante:

$$\left(\underbrace{\bar{X} - Z_{(1-\alpha/2)} \frac{\sigma}{\sqrt{n}}}_a \leq \mu \leq \underbrace{\bar{X} + Z_{(1-\alpha/2)} \frac{\sigma}{\sqrt{n}}}_b \right)$$

donde a y b son valores numéricos que representan el Límite inferior y Límite superior del intervalo de confianza. En caso $n > 30$, el requisito de normalidad de la variable se flexibiliza.

Interpretación: Con un nivel de confianza del $(1 - \alpha) \times 100\%$, se estima que la media poblacional μ esté contenida en el intervalo $[a, b]$, es decir el procedimiento utilizado para construir este intervalo genera, en el largo plazo, intervalos que contienen la verdadera media poblacional μ en aproximadamente el $(1 - \alpha) \times 100\%$ de los casos.

Caso realista: varianza poblacional desconocida

Si $X_1, \dots, X_n$ es una muestra aleatoria de una población Normal con media μ y σ^2 desconocida, el intervalo con un nivel de confianza del $(1 - \alpha) \times 100\%$ para la media μ se obtiene mediante:

$$\left(\underbrace{\bar{X} - t_{(1-\alpha/2; n-1)} \frac{s}{\sqrt{n}}}_a \leq \mu \leq \underbrace{\bar{X} + t_{(1-\alpha/2; n-1)} \frac{s}{\sqrt{n}}}_b \right)$$

donde a y b son valores numéricos que representan el Límite inferior y Límite superior del intervalo de confianza. En caso $n > 30$, el requisito de normalidad de la variable se flexibiliza.

Interpretación: Con un nivel de confianza del $(1 - \alpha) \times 100\%$, se estima que la media poblacional μ esté contenida en el intervalo $[a, b]$, es decir el procedimiento utilizado para construir este intervalo genera, en el largo plazo, intervalos que contienen la verdadera media poblacional μ en aproximadamente el $(1 - \alpha) \times 100\%$ de los casos.

En resumen, para estimar la media μ por intervalo de confianza:

1. Si la variable aleatoria sigue distribución Normal:
 - 1.1 Varianza conocida: Usar $N(0, 1)$, ya que la distribución de $\bar{X}$ es exacta.
 - 1.2 Varianza desconocida y n grande: Usar t_{n-1} aunque se aproxima a $N(0, 1)$.
 - 1.3 Varianza desconocida y n pequeño: Usar t_{n-1} .
2. Si la variable aleatoria no sigue una distribución Normal:
 - 2.1 Varianza conocida y n grande: Usar $N(0, 1)$ ya que por TLC, $\bar{X} \sim N$.
 - 2.2 Varianza conocida y n pequeño: Usar métodos computacionales.
 - 2.3 Varianza desconocida y n grande: Usar $N(0, 1)$.
 - 2.4 Varianza desconocida y n pequeño: Usar métodos computacionales.

Ejemplo 1

Una investigadora estudia la longitud de las hojas de una planta nativa y desea estimar la media poblacional. Para ello, mide una muestra aleatoria de 8 hojas, obteniendo los siguientes valores (en centímetros):

7.8, 8.2, 7.5, 8.0, 8.3, 7.9, 7.6, 8.1

Se desea construir un intervalo de confianza del 95% para la media poblacional de la longitud de las hojas, asumiendo que la variable sigue una distribución normal y que la varianza poblacional es desconocida.

```
hojas <- c(7.8, 8.7, 7.2, 8.0, 8.3, 7.9, 7.6, 8.1)
library(magrittr)
hojas |> t.test() |> use_series(conf.int)
```

```
[1] 7.573459 8.326541
attr(,"conf.level")
[1] 0.95
```

Con un nivel de confianza del 95%, podemos afirmar que el verdadero valor de la longitud promedio de las hojas está entre 7.57 cm y 8.33 cm.

```
hojas |> t.test(conf.level = 0.90) |> use_series(conf.int) # para otro nivel
```

```
[1] 7.648309 8.251691
attr(,"conf.level")
[1] 0.9
```



```
n      <- hojas |> length()
x_bar  <- hojas |> mean()
s      <- hojas |> sd()
gl     <- n - 1
alpha  <- 0.05
tcrit  <- qt(1 - alpha/2, df = gl)
se     <- s / sqrt(n) # error estándar
li     <- x_bar - tcrit * se
ls     <- x_bar + tcrit * se
c(li,ls)
```

```
[1] 7.573459 8.326541
```

Notar que aquí no es válida la aproximación a la distribución Normal, ya que $n = 8$

```
n      <- hojas |> length()
x_bar  <- hojas |> mean()
s      <- hojas |> sd()
alpha  <- 0.05
zcrit  <- qnorm(1 - alpha/2)
se     <- s / sqrt(n) # error estándar
li     <- x_bar - zcrit * se
ls     <- x_bar + zcrit * se
c(li,ls)
```

```
[1] 7.637897 8.262103
```

Ejemplo 2

Una municipalidad metropolitana desea estimar el tiempo promedio que tardan los ciudadanos en llegar a sus centros de trabajo usando transporte público. Con este objetivo, se encuestó a una muestra aleatoria de 60 personas que se movilizan diariamente en bus o metro.

Los tiempos registrados (en minutos) fueron los siguientes:

78, 82, 85, 80, 77, 83, 79, 81, 86, 80, 82, 84, 78, 87, 81, 79, 83,
82, 80, 84, 81, 79, 85, 80, 82, 78, 86, 81, 80, 83, 77, 79, 84, 82,
80, 78, 86, 83, 79, 80, 82, 81, 77, 85, 80, 79, 83, 82, 78, 84, 81,
79, 80, 77, 86, 82, 80, 81, 83, 78

Se desea construir un intervalo de confianza del 95% para el tiempo promedio de traslado al trabajo, asumiendo que la varianza poblacional es desconocida.

```
tiempos = c(78, 82, 85, 80, 77, 83, 79, 81, 86, 80, 82, 84, 78, 87,  
81, 79, 83, 82, 80, 84, 81, 79, 85, 80, 82, 78, 86, 81, 80, 83, 77,  
79, 84, 82, 80, 78, 86, 83, 79, 80, 82, 81, 77, 85, 80, 79, 83, 82,  
78, 84, 81, 79, 80, 77, 86, 82, 80, 81, 83, 78)  
tiempos |> t.test() |> use_series(conf.int)
```

```
[1] 80.52268 81.87732  
attr(,"conf.level")  
[1] 0.95
```

Con un nivel de confianza del 95%, podemos afirmar que el verdadero tiempo promedio de traslado al trabajo está contenido entre 80.52 y 81.88 minutos.

```
n      <- tiempos |> length()
x_bar  <- tiempos |> mean()
s      <- tiempos |> sd()
gl     <- n - 1
alpha  <- 0.05
tcrit  <- qt(1 - alpha/2, df = gl)
se     <- s / sqrt(n) # error estándar
li     <- x_bar - tcrit * se
ls     <- x_bar + tcrit * se
c(li,ls)
```

```
[1] 80.52268 81.87732
```

Notar que aquí sí es válida la aproximación a la distribución Normal, ya que $n = 60 > 30$

```
n      <- tiempos |> length()
x_bar  <- tiempos |> mean()
s      <- tiempos |> sd()
alpha  <- 0.05
zcrit  <- qnorm(1 - alpha/2)
se     <- s / sqrt(n) # error estándar
li     <- x_bar - zcrit * se
ls     <- x_bar + zcrit * se
c(li,ls)
```

```
[1] 80.53657 81.86343
```

Estimación de la varianza por intervalo de confianza

Si $X_1, \dots, X_n$ es una muestra aleatoria de una población Normal con μ y σ^2 desconocida, el intervalo con un nivel de confianza del $(1 - \alpha) \times 100\%$ para la varianza σ^2 se obtiene mediante

$$\underbrace{\frac{(n-1)s^2}{\chi^2_{(1-\alpha/2; n-1)}}}_a \leq \sigma^2 \leq \underbrace{\frac{(n-1)s^2}{\chi^2_{(\alpha/2; n-1)}}}_b$$

donde a y b son valores numéricos que representan el Límite inferior y Límite superior del intervalo de confianza. Para cualquier valor de n se debe verificar Normalidad.

Interpretación: Con un nivel de confianza del $(1 - \alpha) \times 100\%$, se estima que la varianza poblacional σ^2 esté contenida en el intervalo $[a, b]$.

Si se desea obtener los límites de confianza para la desviación estándar se obtiene la raíz cuadrada en la expresión anterior obteniéndose:

$$\sqrt{\frac{(n-1)s^2}{\chi^2_{(1-\alpha/2; n-1)}}} \leq \sigma \leq \sqrt{\frac{(n-1)s^2}{\chi^2_{(\alpha/2; n-1)}}}$$

Ejemplo 3

Un laboratorio analiza el contenido de sodio (en mg/L) en muestras de agua de una planta de tratamiento. Se toma una muestra aleatoria de $n = 12$ unidades, obteniendo los siguientes datos:

43, 39, 45, 48, 46, 50, 44, 49, 47, 46, 42, 41

Se desea construir un intervalo de confianza del 95% para la varianza poblacional σ^2 , asumiendo que el contenido de sodio sigue una distribución Normal.


```
sodio = c(43, 39, 45, 48, 46, 50, 44, 49, 47, 46, 42, 41)
library(EnvStats)
sodio |>
  varTest(conf.level = 0.95)|>
  use_series(conf.int)
```

```
      LCL      UCL
5.565681 31.972759
attr(,"conf.level")
[1] 0.95
```

Con un nivel de confianza del 95%, podemos afirmar que la verdadera varianza del contenido de sodio está contenida entre 5.57 y 31.97 $(mg/L)^2$

```
n      <- sodio |> length()
s2     <- sodio |> var()
alpha  <- 0.05
gl     <- n - 1
chi2_inf <- qchisq(1 - alpha/2, df = gl)
chi2_sup <- qchisq(alpha/2, df = gl)
li_var  <- (gl * s2) / chi2_inf
ls_var  <- (gl * s2) / chi2_sup
c(li_var, ls_var)
```

```
[1] 5.565681 31.972759
```

```
c(li_var, ls_var) |> sqrt() # IC para desviación estándar
```

```
[1] 2.359170 5.654446
```


Estimación de la proporción por intervalo de confianza

Si $X_1, \dots, X_n$ es una muestra aleatoria donde cada X_i indica la presencia (1) o ausencia (0) de una característica, p es la proporción muestral de elementos con dicha característica, $n > 30$, $np > 5$ y $n(1 - p) > 5$, entonces el intervalo con un nivel de confianza del $(1 - \alpha) \times 100\%$ para la proporción π se obtiene mediante

$$\underbrace{p - Z_{(1-\alpha/2)} \sqrt{\frac{p(1-p)}{n}}}_a \leq \pi \leq \underbrace{p + Z_{(1-\alpha/2)} \sqrt{\frac{p(1-p)}{n}}}_b$$

donde a y b son valores numéricos que representan el Límite inferior y Límite superior del intervalo de confianza.

Ver el siguiente video sobre intervalos de confianza (click aquí)



Ejemplo 4

Un equipo de investigadores está evaluando la presencia de plagas en árboles de una plantación forestal. Para ello, se selecciona aleatoriamente una muestra de 150 árboles, y se observa que 36 de ellos presentan signos visibles de infestación.

Se desea construir un intervalo de confianza del 95% para estimar la proporción poblacional de árboles infestados en toda la plantación.

```
library(binom)
binom.confint(x = 36, n = 150, methods = "asymptotic")
```

	method	x	n	mean	lower	upper
1	asymptotic	36	150	0.24	0.1716537	0.3083463

```
n      <- 150
x      <- 36
p      <- x/n
alpha  <- 0.05
zcrit  <- qnorm(1-alpha/2)
li     <- p - zcrit*sqrt(p*(1-p)/n)
ls     <- p + zcrit*sqrt(p*(1-p)/n)
c(li,ls)
```

```
[1] 0.1716537 0.3083463
```

Con un nivel de confianza del 95%, podemos afirmar que la verdadera proporción de árboles infestados está contenida entre 0.1717 y 0.3083.

Cuando la proporción es cercana a 0 o 1, y/o la muestra es pequeña, se sugiere utilizar la aproximación de Wilson, que brinda un intervalo asimétrico e incluido siempre en el intervalo $[0, 1]$.

$$\text{Límite inferior} = \frac{p + \frac{z^2}{2n} - z \cdot \sqrt{\frac{p(1-p)}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}$$

$$\text{Límite superior} = \frac{p + \frac{z^2}{2n} + z \cdot \sqrt{\frac{p(1-p)}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}$$

Ejemplo 5

Un equipo de biólogos está monitoreando la presencia de un insecto invasor en zonas protegidas. Se colocan trampas en 44 ubicaciones diferentes, y solo 2 trampas detectan presencia del insecto. Se desea estimar, con un intervalo de confianza del 95%, la proporción de zonas afectadas por el insecto.

```
prop.test(x = 2, n = 44, correct = FALSE)$conf.int
```

```
[1] 0.01255511 0.15134998  
attr("conf.level")  
[1] 0.95
```

```
binom.confint(x = 2, n = 44, methods = "wilson")
```

	method	x	n	mean	lower	upper
1	wilson	2	44	0.04545455	0.01255511	0.15135

Con un nivel de confianza del 95%, podemos afirmar que la verdadera proporción de zonas afectadas por el insecto está en el intervalo $[0.0126, 0.1514]$.


```
n      <- 44
x      <- 2
p      <- x/n
alpha  <- 0.05
zcrit  <- qnorm(1-alpha/2)
num_li <- (p+zcrit**2/(2*n)-zcrit*sqrt(p*(1-p)/n+zcrit**2/(4*n**2)))
num_ls <- (p+zcrit**2/(2*n)+zcrit*sqrt(p*(1-p)/n+zcrit**2/(4*n**2)))
li_wilson <- num_li/(1+zcrit**2/n)
ls_wilson <- num_ls/(1+zcrit**2/n)
c(li_wilson,ls_wilson)
```

```
[1] 0.01255511 0.15134998
```

Cuando la proporción es cercana (o igual) a 0 o 1, y/o el tamaño muestral es muy pequeño, se recomienda utilizar el método exacto. Este método proporciona un intervalo de confianza asimétrico, siempre contenido en el rango $[0, 1]$ y que garantiza el nivel de confianza especificado. En el ejemplo que venimos desarrollando:

```
binom.confint(x, n, methods = "exact")
```

	method	x	n	mean	lower	upper
1	exact	2	44	0.04545455	0.005552952	0.1547316

```
binom.test(x = x, n = n) |> use_series(conf.int)
```

```
[1] 0.005552952 0.154731578  
attr("conf.level")  
[1] 0.95
```

```
li_exacto <- qbeta(alpha/2, x, n - x + 1)
ls_exacto <- qbeta(1 - alpha/2, x + 1, n - x)
c(li_exacto, ls_exacto)
```

```
[1] 0.005552952 0.154731578
```

Con un nivel de confianza del 95%, podemos afirmar que la verdadera proporción de zonas afectadas por el insecto está en el intervalo $[0.0056, 0.1547]$.

Ejemplo 6

Durante una campaña de vacunación contra la fiebre amarilla en una zona rural, se hace un seguimiento a 18 personas vacunadas. De ellas, solo 1 reporta un efecto adverso leve (como fiebre o dolor muscular) en las 48 horas posteriores.

Se desea construir un intervalo de confianza del 95% para la proporción poblacional de personas que podrían presentar un efecto adverso leve tras recibir la vacuna.

```
x = 1  
n = 18
```

```
binom.confint(x, n, methods = "asymptotic") # Aproximación Normal
```

	method	x	n	mean	lower	upper
1	asymptotic	1	18	0.05555556	-0.05026348	0.1613746

```
binom.confint(x, n, methods = "wilson") # Aproximación de Wilson
```

	method	x	n	mean	lower	upper
1	wilson	1	18	0.05555556	0.009875191	0.257573

```
binom.confint(x, n, methods = "exact") # Método exacto
```

	method	x	n	mean	lower	upper
1	exact	1	18	0.05555556	0.001405556	0.2729436

Interpretar el intervalo adecuado para el caso.

Prueba de hipótesis

Hipótesis estadística

Una hipótesis estadística es una afirmación sobre la distribución de probabilidad de una población o sobre el valor o valores de uno o más parámetros, como la media (μ), la variancia (σ^2) o la proporción (π).

Esta afirmación debe estar basada en la comprensión del fenómeno y sus variables. Una buena hipótesis permite hacer predicciones específicas y, si es rechazada, ayuda a revelar la complejidad del fenómeno.

Tipos de hipótesis estadísticas

Hipótesis nula (H_0 o H_p): Es la hipótesis que es aceptada provisionalmente como verdadera y cuya validez será sometida a verificación experimental. Los resultados experimentales nos permitirán seguir aceptándola como verdadera o si debemos rechazarla como tal.

Hipótesis alterna (H_1 o H_a): Es la hipótesis que se acepta en caso de que la hipótesis nula sea rechazada. La H_1 es la suposición contraria a H_0 .

Prueba de hipótesis

Una prueba de hipótesis es un proceso estructurado para tomar decisiones basadas en datos. Se fundamenta en el método hipotético-deductivo, donde las hipótesis se contrastan con la evidencia en lugar de verificarse directamente.

Una prueba de hipótesis estadística es el proceso mediante el cual se toma la decisión de aceptar o rechazar la hipótesis nula.

El proceso de prueba de hipótesis determina si se rechaza o no H_0 , pero **no se prueba su veracidad absoluta**.

Plantear hipótesis **antes del análisis de datos** (hipótesis a priori) mejora la solidez del estudio, enfocando la prueba en relaciones específicas y reduciendo sesgos.

Tipos de pruebas de hipótesis

En principio, se pueden formular hasta tres tipos de prueba, la cual dependerá de la forma de la hipótesis alterna que se plantee en el estudio:

Hipótesis unilateral con cola a la derecha	Hipótesis bilateral o de dos colas	Hipótesis unilateral con cola a la izquierda
$H_0 : \theta \leq \theta_0$ $H_1 : \theta > \theta_0$	$H_0 : \theta = \theta_0$ $H_1 : \theta \neq \theta_0$	$H_0 : \theta \geq \theta_0$ $H_1 : \theta < \theta_0$

donde θ es el parámetro de interés a probarse, pudiendo ser μ , σ^2 , π (o algún otro que, por cuestiones de tiempo y/o complejidad no es abordado en el curso), y θ_0 es el valor o los valores supuestos que puede tomar el parámetro.

Ejemplo 7

Enunciado	Formulación de la hipótesis	Tipo de prueba de hipótesis
El tiempo promedio de respuesta de una IA educativa no debe superar los 2.5 segundos.	$H_0 : \mu \leq 2.50$ $H_1 : \mu > 2.50$	Unilateral derecha
El porcentaje de estudiantes que aprueban un curso con clases híbridas no es 70%.	$H_0 : \pi = 0.70$ $H_1 : \pi \neq 0.70$	Bilateral
La varianza de los niveles de CO ₂ en aulas ventiladas debe ser menor que 400 ppm ² .	$H_0 : \sigma^2 \geq 400$ $H_1 : \sigma^2 < 400$	Unilateral izquierda
El peso promedio de una variedad mejorada de palta Hass es mayor a 280 gramos.	$H_0 : \mu \leq 280$ $H_1 : \mu > 280$	Unilateral derecha
La desviación en el consumo de energía entre dos modalidades de iluminación LED no difiere significativamente.	$H_0 : \sigma_1^2 = \sigma_2^2$ $H_1 : \sigma_1^2 \neq \sigma_2^2$	Bilateral

Tipo de Errores

Al tomarse una decisión respecto a una hipótesis nula (H_0), se puede presentar cuatro posibles casos que determinan si la decisión tomada es correcta o incorrecta, esto se presenta en la siguiente tabla:

Decisión	H_0 verdadera	H_0 falsa
Aceptar H_0	Decisión correcta con probabilidad $1 - \alpha$	Error tipo II con probabilidad β
Rechazar H_0	Error tipo I con probabilidad α	Decisión correcta con probabilidad $1 - \beta$

La probabilidad de cometer error tipo I se denota por α , conocido como nivel de significación. Determina el tamaño de la zona de rechazo de H_0

La probabilidad de cometer error tipo II se denota por β . Su complemento ($1 - \beta$) es conocido como potencia de prueba.

Pruebas de hipótesis para un parámetro (una población)

Prueba de hipótesis para una media

- ▶ Supuestos: Población normal o $n \geq 30$, e independencia de observaciones
- ▶ Hipótesis:
 - ▶ Unilateral a la derecha: $H_0 : \mu \leq \mu_0$ versus $H_1 : \mu > \mu_0$
 - ▶ Unilateral a la izquierda: $H_0 : \mu \geq \mu_0$ versus $H_1 : \mu < \mu_0$
 - ▶ Bilateral: $H_0 : \mu = \mu_0$ versus $H_1 : \mu \neq \mu_0$
- ▶ Estadístico de prueba:

$$t_{calc} = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t_{(n-1)}$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

** Ejemplo 8 **

Una universidad afirma que sus estudiantes dedican en promedio 4 horas diarias al estudio. Se sospecha que el promedio es realmente menor, por lo que se toma una muestra aleatoria de 35 estudiantes, quienes reportan las siguientes horas de estudio:

2.8, 3.9, 4.2, 2.1, 3.7, 4.5, 3.8, 4.1, 4.6, 3.6, 4.3, 4.0, 2.9, 1.4,
3.9, 4.5, 4.2, 4.0, 3.8, 1.0, 4.7, 3.5, 2.1, 2.2, 3.6, 4.3, 4.8, 4.2,
3.9, 3.7, 4.4, 3.0, 3.8, 4.6, 2.5

Verificar la afirmación con un nivel de significancia del 10%.

$$H_0 : \mu \geq 4 \quad H_1 : \mu < 4 \quad \alpha = 0.10$$

```
tiempo <- c(2.8, 3.9, 4.2, 2.1, 3.7, 4.5, 3.8, 4.1, 4.6, 3.6, 4.3, 4.0,  
           2.9, 1.4, 3.9, 4.5, 4.2, 4.0, 3.8, 1.0, 4.7, 3.5, 2.1, 2.2,  
           3.6, 4.3, 4.8, 4.2, 3.9, 3.7, 4.4, 3.0, 3.8, 4.6, 2.5)  
(tcalc <- (mean(tiempo) - 4)/(sd(tiempo)/sqrt(length(tiempo))))
```

```
[1] -2.383265
```

```
(tcrit <- qt(p = 0.10, df = length(tiempo)-1))
```

```
[1] -1.306952
```

$t_{calc} < t_{crit}$ y la hipótesis es unilateral a la izquierda, entonces se rechaza la hipótesis nula. En conclusión...

```
t.test(x = tiempo, mu = 4, alternative = "less")
```

One Sample t-test

data: tiempo

t = -2.3833, df = 34, p-value = 0.01144

alternative hypothesis: true mean is less than 4

95 percent confidence interval:

-Inf 3.88878

sample estimates:

mean of x

3.617143

$p\text{-value} < \alpha$, entonces se rechaza la hipótesis nula. En conclusión...

Si solo tuviésemos datos resumidos:

```
library(BSDA)
tsum.test(
  mean.x = 3.617,
  s.x = 0.95,
  n.x = 35,
  mu = 4,
  alternative = "less")
```

One-sample t-Test

```
data: Summarized x
t = -2.3851, df = 34, p-value = 0.0114
alternative hypothesis: true mean is less than 4
95 percent confidence interval:
    NA 3.888527
sample estimates:
mean of x
    3.617
```


Prueba de hipótesis para una varianza

- ▶ Supuestos: Población normal e independencia de las observaciones
- ▶ Hipótesis:
 - ▶ Unilateral a la derecha: $H_0 : \sigma^2 \leq \sigma_0^2$ versus $H_1 : \sigma^2 > \sigma_0^2$
 - ▶ Unilateral a la izquierda: $H_0 : \sigma^2 \geq \sigma_0^2$ versus $H_1 : \sigma^2 < \sigma_0^2$
 - ▶ Bilateral: $H_0 : \sigma^2 = \sigma_0^2$ versus $H_1 : \sigma^2 \neq \sigma_0^2$
- ▶ Estadístico de prueba:

$$\chi_{calc}^2 = \frac{(n-1)s^2}{\sigma_0^2} \sim \chi_{(n-1)}^2$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

Ejemplo 9

Para los mismos datos de tiempo de estudio, se sospecha que la varianza es mayor a 1 hora. ¿Se puede verificar dicha afirmación con un nivel de significancia del 10%?

$$H_0 : \sigma^2 \leq 1 \quad H_1 : \sigma^2 > 1 \quad \alpha = 0.10$$

```
(chicalc = (length(tiempo)-1)*var(tiempo)/1)
```

```
[1] 30.70971
```

```
(chicrit = qchisq(p = 0.90, df = length(tiempo)-1))
```

```
[1] 44.90316
```

```
library(EnvStats)
```

```
varTest(x = tiempo, sigma.squared = 1, alternative = "greater")
```

```
$statistic  
Chi-Squared  
30.70971
```

```
$parameters  
df  
34
```

```
$p.value  
[1] 0.6296898
```

```
$estimate  
variance  
0.9032269
```

```
$null.value  
variance  
1
```

```
$alternative  
[1] "greater"
```

```
$method  
[1] "Chi-Squared Test on Variance"
```

Prueba de hipótesis para una proporción

- ▶ Supuestos: $n\pi_0 \geq 5$, $n(1 - \pi_0) \geq 5$ e independencia de las observaciones
- ▶ Hipótesis:
 - ▶ Unilateral a la derecha: $H_0 : \pi \leq \pi_0$ versus $H_1 : \pi > \pi_0$
 - ▶ Unilateral a la izquierda: $H_0 : \pi \geq \pi_0$ versus $H_1 : \pi < \pi_0$
 - ▶ Bilateral: $H_0 : \pi = \pi_0$ versus $H_1 : \pi \neq \pi_0$
- ▶ Estadístico de prueba:

$$Z_{calc} = \frac{p - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}} \sim N(0, 1)$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

Ejemplo

Una universidad sostiene que el 80% de los estudiantes están satisfechos con el servicio de la biblioteca. Se encuesta a 100 estudiantes al azar y 71 dicen estar satisfechos. Verificar si la proporción real difiere de 0.80, con un nivel de significancia del 5%.

$$H_0 : \pi = 0.80 \quad H_1 : \pi \neq 0.80 \quad \alpha = 0.05$$

```
p <- 71/100  
(Z_calc <- (p - 0.8) / sqrt(0.8 * (1 - 0.8) / 100))
```

```
[1] -2.25
```

```
(Z_crit1 <- qnorm(0.025))
```

```
[1] -1.959964
```

```
(Z_crit2 <- qnorm(0.975))
```

```
[1] 1.959964
```

```
prop.test(x=71, n=100, p=0.80, alternative = "two.sided", correct = F)
```

1-sample proportions test without continuity correction

data: 71 out of 100, null probability 0.8

X-squared = 5.0625, df = 1, p-value = 0.02445

alternative hypothesis: true p is not equal to 0.8

95 percent confidence interval:

0.6146111 0.7898516

sample estimates:

p

0.71

Pruebas de hipótesis para dos parámetros (dos poblaciones)

Prueba de hipótesis de homogeneidad de dos varianzas

- ▶ Supuestos: Ambas poblaciones normales e independientes entre ellas, así como independencia de las observaciones dentro de cada muestra
- ▶ Hipótesis: $H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1$ versus $H_1 : \frac{\sigma_1^2}{\sigma_2^2} \neq 1$
- ▶ Estadístico de prueba:

$$F_{calc} = \frac{s_1^2}{s_2^2} \sim F_{(n_1-1, n_2-1)}$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

Ejemplo

Un laboratorio desea determinar si la variabilidad de concentración (en mg/L) de un fármaco en la sangre es igual para dos fabricantes distintos, considerando un nivel de significancia del 10%. Los datos de concentración con el fabricante A son: 8.1, 7.9, 8.3, 7.8, 8.0, 8.2, 7.7, mientras que con el fabricante B: 7.5, 7.2, 7.1, 7.4, 7.3, 7.6, 7.2, 7.5.

$$H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1 \quad H_1 : \frac{\sigma_A^2}{\sigma_B^2} \neq 1 \quad \alpha = 0.10$$


```
A <- c(8.1, 7.9, 8.3, 7.8, 8.0, 8.2, 7.7)
B <- c(7.5, 7.2, 7.1, 7.4, 7.3, 7.6, 7.2, 7.5)
(Fcalc <- var(A)/var(B))
```

```
[1] 1.484848
```

```
(Fcrit1 <- qf(0.05, 6, 7))
```

```
[1] 0.2377184
```

```
(Fcrit2 <- qf(0.95, 6, 7))
```

```
[1] 3.865969
```

```
var.test(A, B, alternative = "two.sided", ratio = 1)
```

F test to compare two variances

data: A and B

F = 1.4848, num df = 6, denom df = 7, p-value = 0.6136

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

0.290089 8.456911

sample estimates:

ratio of variances

1.484848

Prueba de hipótesis para dos medias independientes

- ▶ Supuestos: Ambas poblaciones normales (o con tamaño de muestra grande $n > 30$ cada una) e independientes entre ellas, así como independencia de las observaciones dentro de cada muestra
- ▶ Hipótesis:
 - ▶ Unilateral a la derecha: $H_0 : \mu_1 - \mu_2 \leq \mu_0$ versus $H_1 : \mu_1 - \mu_2 > \mu_0$
 - ▶ Unilateral a la izquierda: $H_0 : \mu_1 - \mu_2 \geq \mu_0$ versus $H_1 : \mu_1 - \mu_2 < \mu_0$
 - ▶ Bilateral: $H_0 : \mu_1 - \mu_2 = \mu_0$ versus $H_1 : \mu_1 - \mu_2 \neq \mu_0$
- ▶ Estadístico de prueba:
 - ▶ Varianzas iguales:

$$t = \frac{\bar{X}_1 - \bar{X}_2 - \mu_0}{\sqrt{s_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim t_{(n_1+n_2-2)} \quad \text{donde} \quad s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

- ▶ Varianzas distintas:

$$t = \frac{\bar{X}_1 - \bar{X}_2 - \mu_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \sim t_{\nu-Welch}$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

Ejemplo

Queremos comparar los salarios mensuales de trabajadores de dos empresas diferentes a través de sus medias. No conocemos nada acerca de sus varianzas. Considerar $\alpha = 0.10$.

Los datos recolectados en una muestra aleatoria de cada empresa es:

- ▶ Empresa 1: 2500, 2700, 2600, 2800, 2900
- ▶ Empresa 2: 3000, 2100, 3200, 2300, 3400

Primero, debemos verificar si las varianzas son homogéneas:

$$H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1 \quad H_1 : \frac{\sigma_A^2}{\sigma_B^2} \neq 1 \quad \alpha = 0.10$$

```
E1 = c(2500, 2700, 2600, 2800, 2900)
E2 = c(3000, 2100, 3200, 2300, 3400)
var.test(E1, E2, alternative = "two.sided", ratio = 1)
```

F test to compare two variances

data: E1 and E2

F = 0.076923, num df = 4, denom df = 4, p-value = 0.02915

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

0.008009041 0.738809991

sample estimates:

ratio of variances

0.07692308

Ahora procederemos a comparar las medias. Dado que no se especifica una dirección particular en la comparación, se asumirá que el objetivo es determinar si las medias son iguales o diferentes.

$$H_0 : \mu_1 - \mu_2 = 0 \quad H_1 : \mu_1 - \mu_2 \neq 0 \quad \alpha = 0.10$$

```
t.test(E1, E2, alternative = "two.sided", mu = 0, var.equal = F, paired = F)
```

Welch Two Sample t-test

data: E1 and E2

t = -0.37796, df = 4.6118, p-value = 0.7222

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-797.699 597.699

sample estimates:

mean of x mean of y

2700 2800

Ejemplo

Un equipo de agrónomos desea evaluar si el tipo de fertilizante influye en el rendimiento de maíz (kg por parcela). Se aplicaron dos tipos de fertilizante (A y B) en parcelas similares bajo las mismas condiciones de riego y clima. Los investigadores quieren si fertilizante A incrementa el rendimiento del maíz en más de 20 kg/parcela en comparación con el fertilizante B. El estudio se realiza en condiciones controladas y se usa un nivel de significancia del 10%.

- ▶ Fertilizante A: 820, 830, 815, 860, 825, 835, 822
- ▶ Fertilizante B: 800, 805, 798, 810, 802, 799, 803, 777, 789, 815

$$H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1 \quad H_1 : \frac{\sigma_A^2}{\sigma_B^2} \neq 1 \quad \alpha = 0.10$$

```
A <- c(820, 830, 815, 860, 825, 835, 822)
B <- c(800, 805, 798, 810, 802, 799, 803, 777, 789, 815)
var.test(A, B, alternative = "two.sided", ratio = 1)
```

F test to compare two variances

data: A and B

F = 1.9719, num df = 6, denom df = 9, p-value = 0.3457

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

0.45648 10.89142

sample estimates:

ratio of variances

1.971867

Probando la diferencia de medias:

$$H_0 : \mu_1 - \mu_2 \leq 20 \quad H_1 : \mu_1 - \mu_2 > 20 \quad \alpha = 0.10$$

```
A <- c(820, 830, 815, 860, 825, 835, 822)
B <- c(800, 805, 798, 810, 802, 799, 803, 777, 789, 815)
t.test(A, B, alternative = "greater", mu = 20, var.equal = T, paired = F)
```

Two Sample t-test

data: A and B

t = 1.5824, df = 15, p-value = 0.06721

alternative hypothesis: true difference in means is greater than 20

95 percent confidence interval:

18.94591 Inf

sample estimates:

mean of x mean of y

829.5714 799.8000

Prueba de hipótesis para dos medias pareadas

- ▶ Supuestos: Las poblaciones no son independientes. Las diferencias son normales (o con tamaño de muestra grande $n > 30$ cada una) e independientes entre ellas.
- ▶ Hipótesis:
 - ▶ Unilateral a la derecha: $H_0 : \mu_D \leq \mu_0$ versus $H_1 : \mu_D > \mu_0$
 - ▶ Unilateral a la izquierda: $H_0 : \mu_D \geq \mu_0$ versus $H_1 : \mu_D < \mu_0$
 - ▶ Bilateral: $H_0 : \mu_D = \mu_0$ versus $H_1 : \mu_D \neq \mu_0$
- ▶ Estadístico de prueba:

$$t_{calc} = \frac{\bar{d} - \mu_0}{\frac{s_d}{\sqrt{n}}} \sim t_{(n-1)}$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

Ejemplo

Un grupo de agrónomos desea evaluar el efecto de un regulador de crecimiento sobre la altura de plantas de tomate. Se midieron las alturas de las mismas plantas antes y después de aplicar el producto, por lo que se trata de un diseño pareado. Se quiere saber si el producto genera un aumento promedio mayor a 3 cm, utilizando un nivel de significancia del 5%.

Los datos recolectados antes y después de la aplicación del producto son: - Antes: 120, 122, 121, 119, 118, 123, 121, 120, 122, 119, 115, 123 - Después: 125, 127, 126, 124, 123, 129, 126, 125, 128, 123, 116, 129

$$H_0 : \mu_D \leq 3 \quad H_1 : \mu_D > 3 \quad \alpha = 0.05$$

```
antes    = c(120, 122, 121, 119, 118, 123, 121, 120, 122, 119, 115, 123)
despues  = c(125, 127, 126, 124, 123, 129, 126, 125, 128, 123, 116, 129)
t.test(despues, antes, mu = 3, alternative = "greater", paired = T)
```

Paired t-test

data: despues and antes

t = 4.7497, df = 11, p-value = 3e-04

alternative hypothesis: true mean difference is greater than 3

95 percent confidence interval:

4.140136 Inf

sample estimates:

mean difference

4.833333

Prueba de hipótesis para dos proporciones

- ▶ Supuestos: $n\pi \geq 5$ en ambos grupos, e independencia de las observaciones entre grupos y dentro de cada grupo.
- ▶ Hipótesis:
 - ▶ Unilateral a la derecha: $H_0 : \pi_1 - \pi_2 \leq \pi_0$ versus $H_1 : \pi_1 - \pi_2 > \pi_0$
 - ▶ Unilateral a la izquierda: $H_0 : \pi_1 - \pi_2 \geq \pi_0$ versus $H_1 : \pi_1 - \pi_2 < \pi_0$
 - ▶ Bilateral: $H_0 : \pi_1 - \pi_2 = \pi_0$ versus $H_1 : \pi_1 - \pi_2 \neq \pi_0$
- ▶ Estadístico de prueba:

$$Z_{calc} = \frac{p_1 - p_2 - \pi_0}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}}$$

Caso especial: cuando $\pi_0 = 0$, se puede usar proporción combinada:

$$Z_{calc} = \frac{p_1 - p_2 - \pi_0}{\sqrt{\hat{p}(1-\hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \quad \hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

- ▶ Decisión: Comparar con valores críticos o usar p-valor

Ejemplo

Se desea comparar la proporción de hogares que hierven el agua antes de consumirla. En zona urbana: 90 de 120 hogares lo hacen; en zona rural: 80 de 110. ¿Las proporciones son las mismas?

$$H_0 : \pi_{urbana} - \pi_{rural} = 0 \quad H_1 : \pi_{urbana} - \pi_{rural} \neq 0 \quad \alpha = 0.05$$

```
x1 <- 90; n1 <- 120; (p1 <- x1/n1)
```

```
[1] 0.75
```

```
x2 <- 80; n2 <- 110; (p2 <- x2/n2)
```

```
[1] 0.7272727
```

```
(p <- (x1+x2)/(n1+n2))
```

```
[1] 0.7391304
```

```
(zcalc <- (p1-p2)/sqrt(p*(1-p)*(1/n1+1/n2)))
```

```
[1] 0.3921012
```

```
(zcrit1 <- qnorm(0.025))
```

```
[1] -1.959964
```

```
(zcrit2 <- qnorm(0.975))
```

```
[1] 1.959964
```

```
prop.test(x = c(x1, x2), n = c(n1, n2), alternative = "two.sided", correct = F)
```

2-sample test for equality of proportions without continuity correction

data: c(x1, x2) out of c(n1, n2)

X-squared = 0.15374, df = 1, p-value = 0.695

alternative hypothesis: two.sided

95 percent confidence interval:

-0.09097861 0.13643315

sample estimates:

prop 1	prop 2
0.7500000	0.7272727

Ejemplo

Un equipo de especialistas en gestión ambiental desea evaluar si una campaña de sensibilización ambiental logra aumentar sustancialmente la proporción de hogares que clasifican adecuadamente sus residuos sólidos.

- ▶ En el barrio sin campaña, 45 de 100 hogares clasifican correctamente.
- ▶ En el barrio con campaña, 70 de 100 hogares lo hacen.

El equipo busca determinar si la proporción de hogares que clasifican adecuadamente sus residuos sólidos en el barrio con campaña supera en más de un 20% a la del barrio sin campaña, lo cual justificaría su implementación a mayor escala. Para ello, se emplea un nivel de significancia del 5%

$$H_0 : \pi_{con} - \pi_{sin} \leq 0.20 \quad H_1 : \pi_{con} - \pi_{sin} > 0.20 \quad \alpha = 0.05$$

```
x1 <- 70; n1 <- 100; (p1 <- x1/n1)
```

```
[1] 0.7
```

```
x2 <- 45; n2 <- 100; (p2 <- x2/n2)
```

```
[1] 0.45
```

```
(zcalc <- (p1-p2-0.20)/sqrt(p1*(1-p1)/n1+p2*(1-p2)/n2))
```

```
[1] 0.7392213
```

```
(zcrit2 <- qnorm(0.95))
```

```
[1] 1.644854
```

```
(pv <- 1-pnorm(zcalc))
```

```
[1] 0.2298863
```

Ejercicios

1. Un fabricante de focos LED afirma que la vida útil promedio de sus productos es de 15 000 horas. Un cliente sospecha que la vida útil real es menor y toma una muestra de 80 focos, obteniendo una media de 14 800 horas con una desviación estándar de 200 horas. ¿Hay evidencia suficiente, con un nivel de significancia de 5%, para concluir que la vida útil es menor a la declarada?
2. Desde el 2016, las encuestas vienen señalando que el 65% de los peruanos tienen acceso a internet. Un investigador cree que en una determinada región rural la proporción es menor y encuesta a 150 personas, de las cuales 60 no tienen acceso. ¿Se puede afirmar con un 5% de significancia que la proporción en la región es menor?

3. Una empresa quiere comparar el tiempo de producción promedio, en minutos, de dos máquinas diferentes, para ello toma muestras de cada una de ellas:

▶ Máquina A: 12.75, 11.58, 11.95, 11.58, 14.52, 12.28, 11.03, 13.29

▶ Máquina B: 9.9, 11.77, 8.95, 9.77, 11.76, 12.46, 11.72, 11.34, 11.1, 13.57

¿Se puede concluir que la máquina A tarda más con $\alpha = 0.10$? Considerar que el tiempo de producción de cada máquina sigue una distribución Normal.

4. Una organización ambiental desea evaluar si hay diferencia en el uso de bolsas reutilizables entre zonas urbanas y rurales. Se realizó una encuesta a hogares para conocer si utilizan bolsas reutilizables al hacer sus compras:

▶ Hogares urbanos: 300 encuestados, de los cuales 160 afirmaron usar bolsas reutilizables.

▶ Hogares rurales: 180 encuestados, de los cuales 80 afirmaron usarlas.

¿Existe evidencia estadística, con un nivel de significancia del 1%, para concluir que las proporciones de uso de bolsas reutilizables son diferentes entre las zonas urbanas y rurales?